Optimisation des requêtes et schéma d'accès aux données

Rappel SQL

Table

CustomerID	CustomerName	ContactName	Address	City	PostalCode	Country
1	Alfreds Futterkiste	Maria Anders	Obere Str. 57	Berlin	12209	Germany
2	Ana Trujillo Emparedados y helados	Ana Trujillo	Avda. de la Constitución 2222	México D.F.	05021	Mexico
3	Antonio Moreno Taquería	Antonio Moreno	Mataderos 2312	México D.F.	05023	Mexico
4	Around the Horn	Thomas Hardy	120 Hanover Sq.	London	WA1 1DP	UK
5	Berglunds snabbköp	Christina Berglund	Berguvsvägen 8	Luleå	S-958 22	Sweden

Rappel SQL

- Instruction exemple :
 - SELECT * FROM Customers;
- SQL n'est pas sensible à la casse
- On sépare les instructions par des points virgule

Des commandes importants

- SELECT
- UPDATE
- DELETE
- INSERT INTO
- CREATE DATABASE
- ALTER DATABASE
- CREATE TABLE
- ALTER TABLE
- DROP TABLE
- CREATE INDEX
- DROP INDEX

SELECT

```
SELECT * FROM table_name;
Ou
SELECT column_name,column_name
FROM table_name;
```

DISTINCT

SELECT DISTINCT column_name,column_name FROM table_name;

Exemple:

SELECT DISTINCT City FROM Customers;

WHERE

SELECT column_name,column_name FROM table_name WHERE column_name operator value;

Exemple:

SELECT * FROM Customers WHERE Country='Mexico';

AND & OR

```
SELECT * FROM Customers WHERE Country='Germany' AND City='Berlin';
```

```
SELECT * FROM Customers
WHERE City='Berlin'
OR City='München';
```

SELECT * FROM Customers
WHERE Country='Germany'
AND (City='Berlin' OR City='München');

ORDER BY

SELECT column_name, column_name
FROM table_name
ORDER BY column_name ASC|DESC, column_name ASC|DESC;

SELECT * FROM Customers ORDER BY Country;

SELECT * FROM Customers
ORDER BY Country **DESC**;

ORDER BY

SELECT * FROM Customers

ORDER BY Country, CustomerName;

SELECT * FROM Customers

ORDER BY Country **ASC**, CustomerName **DESC**;

INSERT INTO

```
INSERT INTO table_name
VALUES (value1,value2,value3,...);
```

```
INSERT INTO table_name (column1,column2,column3,...)
VALUES (value1,value2,value3,...);
```

INSERT INTO Customers (CustomerName, City, Country) VALUES ('Cardinal', 'Stavanger', 'Norway');

UPDATE

UPDATE table_name SET column1=value1,column2=value2,... WHERE some_column=some_value;

UPDATE Customers **SET** ContactName='Alfred Schmidt', City='Hamburg' **WHERE** CustomerName='Alfreds Futterkiste';

Attention au where

UPDATE Customers **SET** ContactName='Alfred Schmidt', City='Hamburg';

DELETE

DELETE FROM table_name
WHERE some_column=some_value;

DELETE FROM Customers
WHERE CustomerName='Alfreds Futterkiste' AND ContactName='Maria Anders';

Si on met pas where on supprime toutes les données

SQL Injection

L'injection SQL peut detruire votre base de données.

```
txtUserId = getRequestString("UserId");
txtSQL = "SELECT * FROM Users WHERE UserId = " + txtUserId;
```

SELECT * FROM Users WHERE UserId = 105 or 1=1

SELECT * FROM Users WHERE UserId = 105; DROP TABLE Suppliers

Pour se protéger : Requêtes paramétrées

```
$stmt = $dbh->prepare("INSERT INTO Customers
(CustomerName,Address,City)
VALUES (:nam, :add, :cit)");
$stmt->bindParam(':nam', $txtNam);
$stmt->bindParam(':add', $txtAdd);
$stmt->bindParam(':cit', $txtCit);
$stmt->execute();
```

SQL SELECT TOP

SELECT TOP number|percent column_name(s)
FROM table_name;

SELECT column_name(s)
FROM table_name
LIMIT number;

LIKE

SELECT column_name(s)
FROM table_name
WHERE column_name LIKE pattern;

SELECT * FROM Customers WHERE City LIKE 's%';// Tous les clients dont le cité commencent par s

SELECT * FROM Customers
WHERE City LIKE '%s';// Tous les clients dont le cité se terminent par s

SELECT * FROM Customers
WHERE Country LIKE '%land%';// Tous les clients dont le pays contient land

Wildcard

[!charlist]

%: remplace zéro ou plusieurs caractères
_: remplace une seule caractère
[charlist]: ensemble ou intervalles de caractères à trouver

[^charlist]: ensemble ou intervalles de caractères à trouver or

Exemple wildcards

```
SELECT * FROM Customers
WHERE City LIKE 'ber%';
// retourne les clients don't la cité commence par ber
SELECT * FROM Customers
WHERE City LIKE '%es%';
// retourne les clients don't la cité contient es
SELECT * FROM Customers
WHERE City LIKE ' erlin';
// retourne les clients don't la cite commence n'importe quelle caractère suivi par erlin
```

SQL functions

SQL Aggregate Functions
SQL Scalar functions

SQL Aggregate Functions

SQL aggregate functions return a single value, calculated from values in a column.

Useful aggregate functions:

- AVG() Returns the average value
- COUNT() Returns the number of rows
- FIRST() Returns the first value
- LAST() Returns the last value
- MAX() Returns the largest value
- MIN() Returns the smallest value
- SUM() Returns the sum

SQL Scalar functions

- UCASE() Converts a field to upper case
- LCASE() Converts a field to lower case
- MID() Extract characters from a text field
- LEN() Returns the length of a text field
- ROUND() Rounds a numeric field to the number of decimals specified
- NOW() Returns the current system date and time
- FORMAT() Formats how a field is to be displayed

SQL Function : AVG()

Syntax:

SELECT AVG(column_name) FROM table_name

Example:

select AVG(ActualCost) from Production.TransactionHistory

SQL Function: COUNT()

Syntax:

SELECT COUNT(column_name) FROM table_name

To display distinct values:

SELECT COUNT(DISTINCT column_name) FROM table_name;

Example:

select COUNT(*) from Production.TransactionHistory select COUNT(distinct ActualCost) from Production.TransactionHistory

SQL Function : FIRST ()

Syntax:

SELECT FIRST(column_name) FROM table_name;

The FIRST() function is only supported in MS Access.

SELECT TOP 1 column_name FROM table_name ORDER BY column_name ASC;//**SQL Server**

SELECT CustomerName FROM Customers WHERE ROWNUM <=1 ORDER BY CustomerID ASC;//Oracle

SELECT column_name FROM table_name ORDER BY column_name ASC LIMIT 1;//**Mysql**

SQL Function : FIRST ()

Example:

select top 1 * from Production.TransactionHistory order by TransactionID asc

SQL Function: LAST()

Syntax:

SELECT FIRST(column_name) FROM table_name;

The FIRST() function is only supported in MS Access.

SELECT TOP 1 column_name FROM table_name ORDER BY column_name DESC;//**SQL Server**

SELECT CustomerName FROM Customers WHERE ROWNUM <=1 ORDER BY CustomerID DESC;//Oracle

SELECT column_name FROM table_name ORDER BY column_name DESC LIMIT 1;//**Mysql**

SQL Function : LAST ()

Example:

select top 1 * from Production.TransactionHistory order by TransactionID desc

SQL Function : MAX()

Syntax:

SELECT MAX(column_name) FROM table_name

Example:

select MAX(ActualCost) from Production.TransactionHistory

SQL Function: MIN()

Syntax:

SELECT MIN (column_name) FROM table_name

Example:

select MIN (ActualCost) from Production.TransactionHistory

SQL Function : SUM()

Syntax:

SELECT SUM (column_name) FROM table_name

Example:

select SUM (ActualCost) from Production.TransactionHistory

SQL GROUP BY Statement

Syntax:

SELECT column_name, aggregate_function(column_name)
FROM table_name
WHERE column_name operator value
GROUP BY column_name;

Example:

select SUM(ActualCost), t.ModifiedDate, t.Quantity from Production.TransactionHistory t group by t.ModifiedDate, t.Quantity

SQL HAVING Clause

Syntax:

```
SELECT column_name, aggregate_function(column_name) FROM table_name WHERE column_name operator value GROUP BY column_name HAVING aggregate_function(column_name) operator value;
```

Example:

select SUM(ActualCost), t.ModifiedDate, t.Quantity from Production.TransactionHistory t group by t.ModifiedDate, t.Quantity having SUM(ActualCost) > 100

SQL UCASE() Function

Syntax:

SELECT UPPER (column_name) FROM table_name

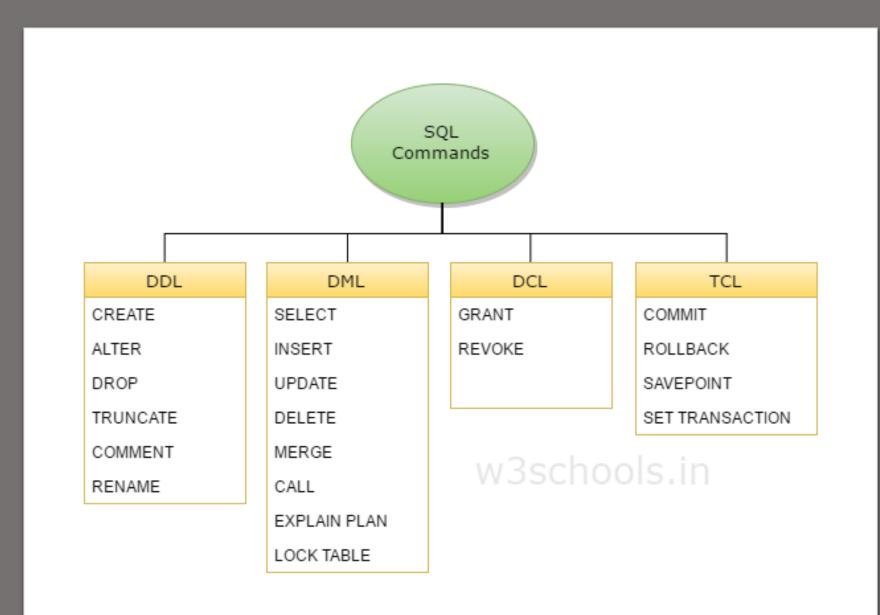
Example:

select UPPER (p.FirstName) from Person.Person p

Datetime vs datetime 2

DECLARE

- @thedatetime2 datetime2(7),
- @thedatetime datetime;
- SET @thedatetime2 = '2025-05-21 10:15:30.5555555';
- SET @thedatetime = @thedatetime2;
- **SELECT**
- @thedatetime2 AS 'datetime2',
- @thedatetime AS 'datetime';



Catégorie des commandes SQL

Procédure stocké et fonctions

Les fonctions retournent une valeur et ne peuvent pas modifier les données qu'elles reçoivent en tant que paramètres (les arguments).

Les fonctions ne sont pas autorisées à modifier quoi que ce soit, doivent avoir au moins un paramètre et doivent renvoyer une valeur. Les proc stockés n'ont pas besoin d'avoir un paramètre, peuvent changer les objets de base de données et n'ont pas besoin de retourner une valeur.



Clustered index and non clustered index



UN INDEX CLUSTERISÉ SIGNIFIE
QUE VOUS INDIQUEZ À LA BASE
DE DONNÉES DE STOCKER SUR LE
DISQUE DES VALEURS PROCHES
LES UNES DES AUTRES (SUR LE
DISQUE). CELA PRÉSENTE
L'AVANTAGE D'ANALYSER / DE
RÉCUPÉRER RAPIDEMENT LES
ENREGISTREMENTS QUI SE
SITUENT DANS UNE PLAGE DE
VALEURS D'INDEX EN CLUSTER.



UN SEUL INDEX CLUSTERED PAR TABLE



LE CI DOIT TOUJOURS ÊTRE UTILISÉ POUR LA PK

Clustered index and non clustered index

Avec un index non clusterisé, il existe une seconde liste qui contient des pointeurs sur les lignes physiques. Vous pouvez avoir plusieurs index non clusterisés, bien que chaque nouvel index augmente le temps nécessaire pour écrire de nouveaux enregistrements.

Il est généralement plus rapide de lire à partir d'un index clusterisé si vous souhaitez récupérer toutes les colonnes. Vous n'êtes pas obligé d'aller d'abord à l'index, puis à la table.

L'écriture dans une table avec un index clusterisé peut être plus lente s'il est nécessaire de réorganiser les données.





Nested Loop join



Merge join



And Hash join

On va exécuter cette requête en SQL server : SELECT e.[BusinessEntityID] ,p.[Title] ,p.[FirstName] ,p.[MiddleName] ,p.[LastName] ,p.[Suffix] ,e.[JobTitle] FROM [HumanResources].[Employee] e INNER JOIN [Person].[Person] p

ON p.[BusinessEntityID] = e.[BusinessEntityID]

C'est maintenant un travail de serveur SQL de créer un plan approprié pour la requête, de l'exécuter et de renvoyer l'ensemble des résultats à l'appelant. SQL Server dispose de plusieurs composants pour effectuer cette série de tâches, notamment l'analyse de requête, la création d'une arborescence de requête, la création d'un plan binaire, l'exécution de la requête et le retour du jeu de résultats.

L'exécution réelle de la requête est gérée par le composant du moteur de stockage de SQL Server.

Pour exécuter la requête ci-dessus, SQL peut sélectionner n'importe laquelle

des actions Nested Loop join, merge joi et hash joins, en fonction de critères tels que :

- Taille de table
- Ordre d'index utilisé dans join
- Index disponibles
- Type d'index Cluster ou non-cluster
- etc

Loop join

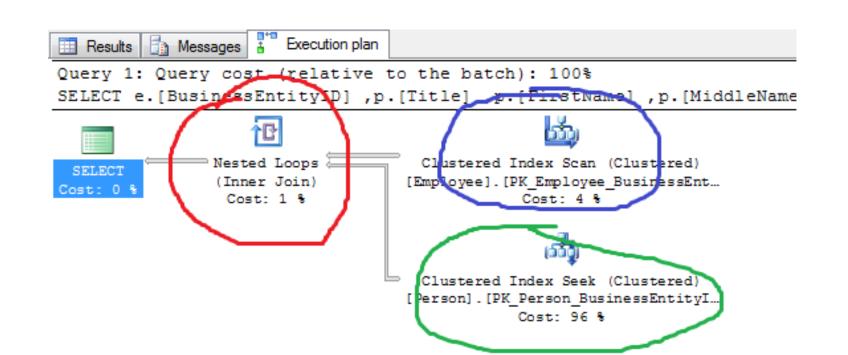
SQL Server choisit Loop join quand un jeu d'entrée est petit et que l'autre est assez volumineux et indexé sur sa colonne de jointure, nested loop join est l'opération de jointure la plus rapide car elle nécessite le moins d'Entrées / Sortie et le moins de comparaisons.

On l'appelle aussi itération imbriquée.

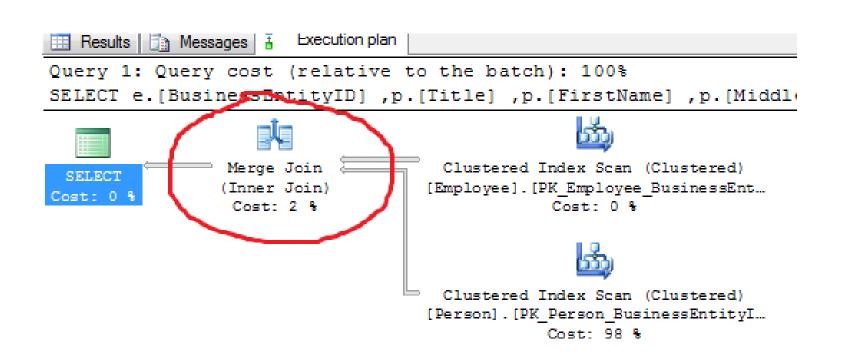
Il est particulièrement efficace si l'entrée externe est petite et si l'entrée interne est préindexée et grande.

Pour de nombreuses petites transactions avec de petits ensembles de données, le type de jointure nested loop est supérieur à merge et hash joins.

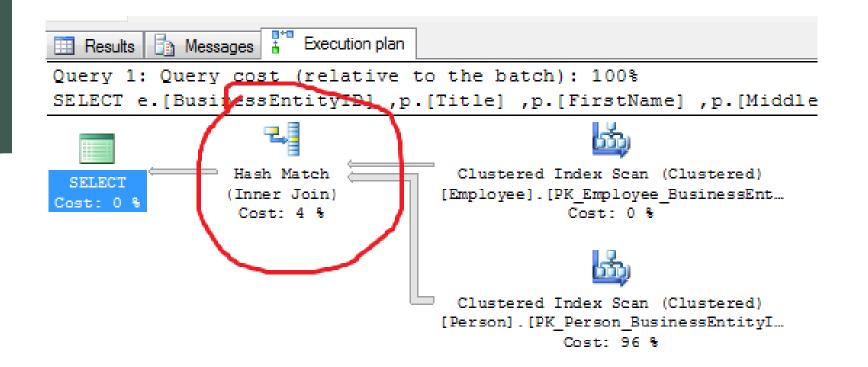
Exemple de plan d'exécution de Loop join

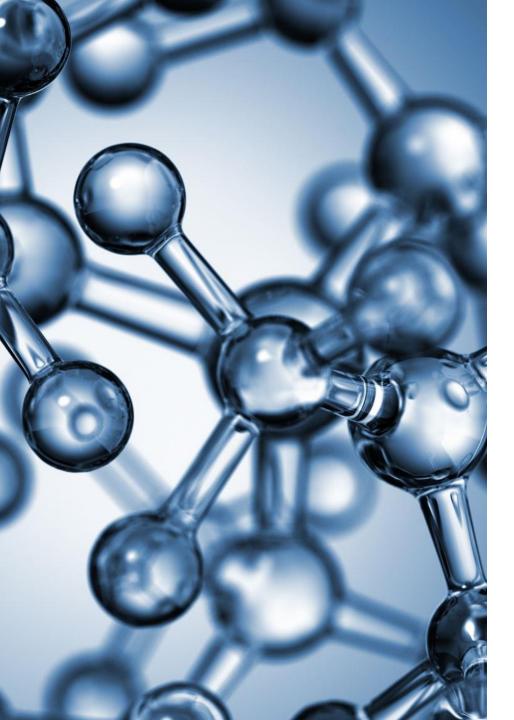


Exemple de plan d'exécution de Merge join



Exemple de plan d'exécution de Hash join





B-Tree and Bitmap index



B-TREE ET BITMAP SONT DEUX TYPES D'INDEX UTILISÉS DANS ORACLE.



BITMAP EST UNE
MÉTHODE
D'INDEXATION
OFFRANT DES
AVANTAGES EN TERMES
DE PERFORMANCES ET
D'ÉCONOMIE DE
STOCKAGE.



L'INDEX B-TREE EST UN INDEX CRÉÉ SUR DES COLONNES CONTENANT DES VALEURS TRÈS UNIQUES.



B-TREE FONCTIONNE MIEUX AVEC DE NOMBREUSES VALEURS INDEXÉES DISTINCTES

BITMAP FONCTIONNE MIEUX AVEC DE NOMBREUSES VALEURS INDEXÉES DISTINCTES

信

Créer des index

On crée une table Person2

La table crée ne contient pas de PK

et ne contient pas d'index

Select into copie la structure de la table sans les PK et les index

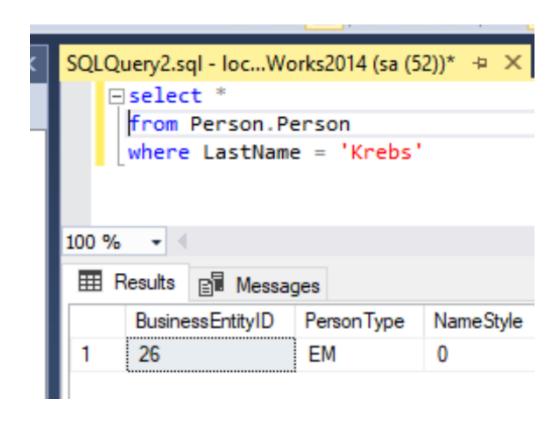
La table Person2 ne possède pas d'index

```
SQLQuery2.sql - loc...Works2014 (sa (52))* + ×

= select *
   into Person.Person2
   from Person.Person
```

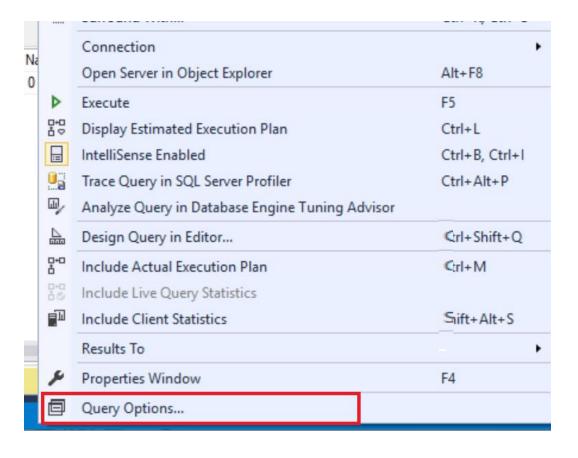
index

On va exécuter la requête suivante :

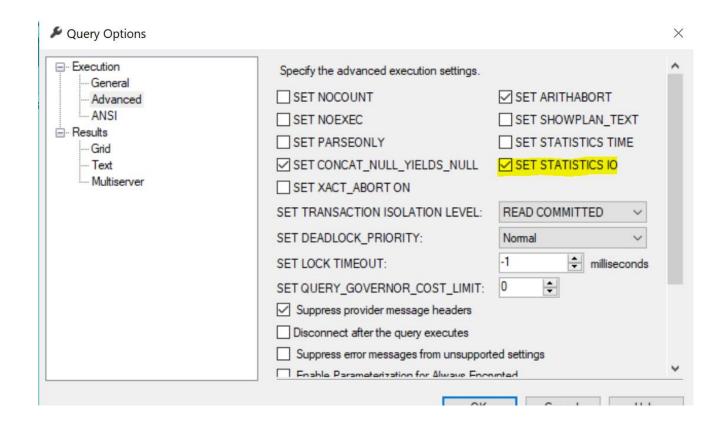


Afficher le plan d'exécution

Clique droit sur la fenêtre de requête et sélectionner query options

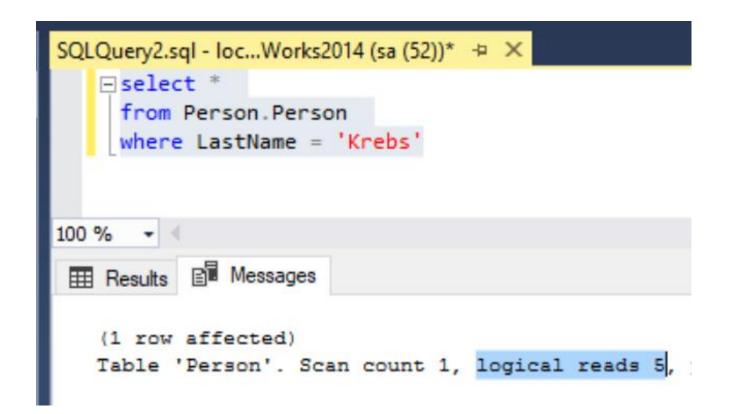


Afficher le plan d'exécution



Choisir set statistics IO

Nombre de lectures logiques avec index



Exécuter cette requête : on a 5 lecture logique

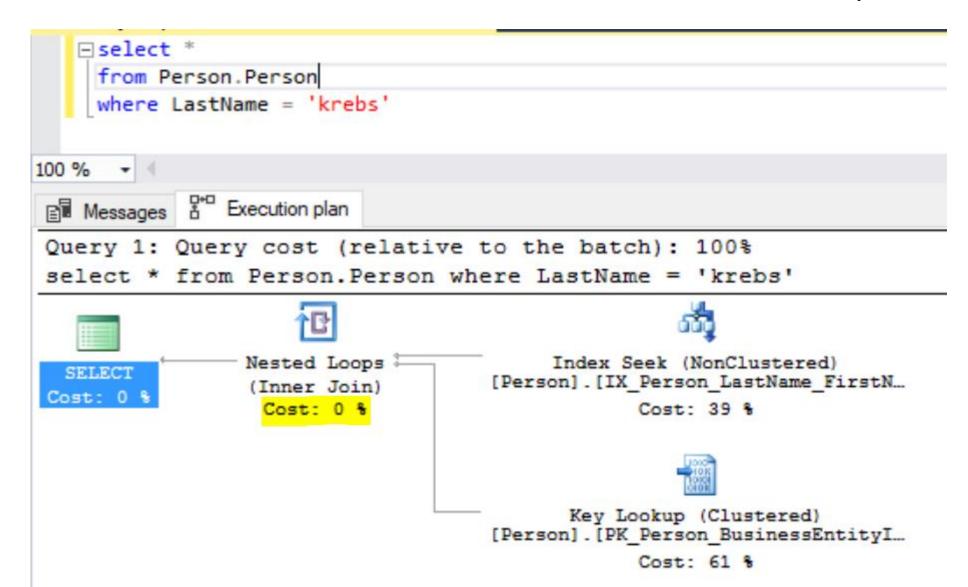
Nombre de lectures logiques sans index

Maintenant on exécute cette requête sur la table qui ne contient pas d'index et on voit le nombre de lecture logique

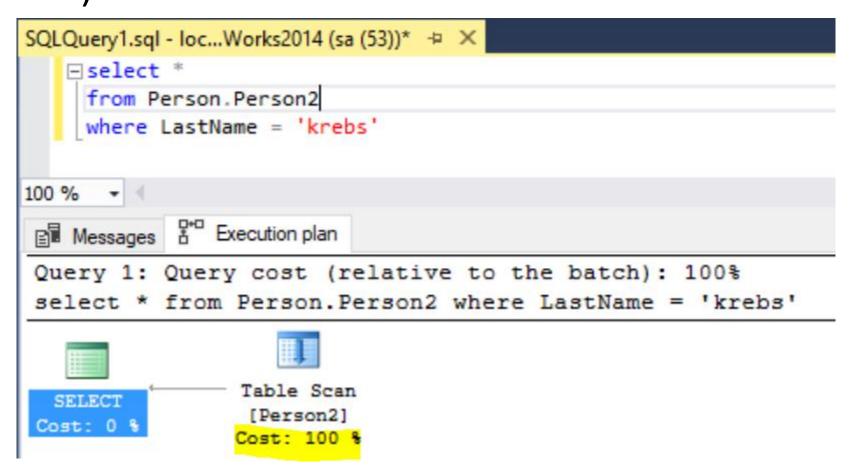
Comparaison des plans d'exécution

On va comparer le plan d'exécution pour les deux tables **Person** qui possède un index et Person2 qui ne possède pas d'index

Plan d'exécution de la table Person (indexé)



Plan d'exécution de la table Person2 (non indexé)

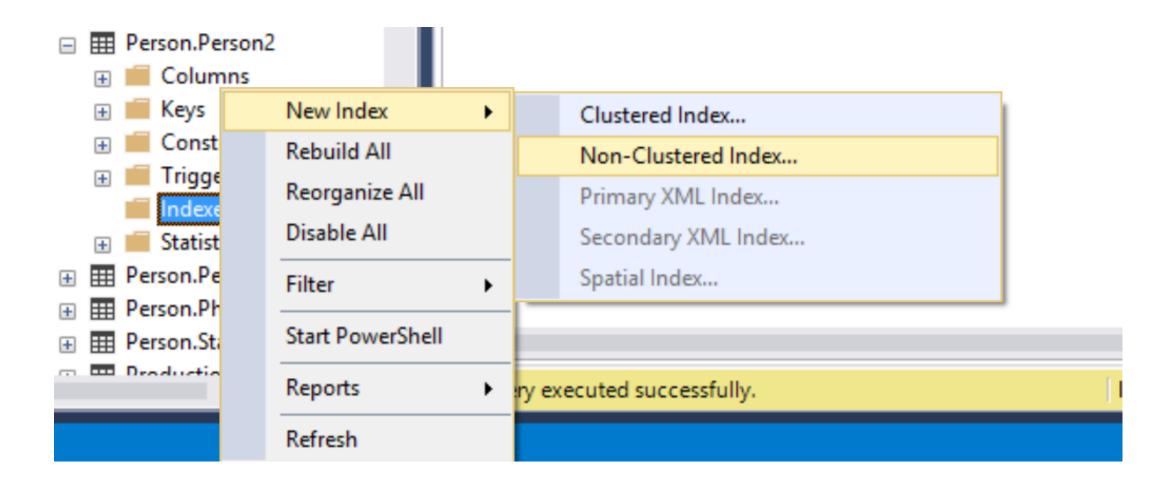


La recherche dichotomique

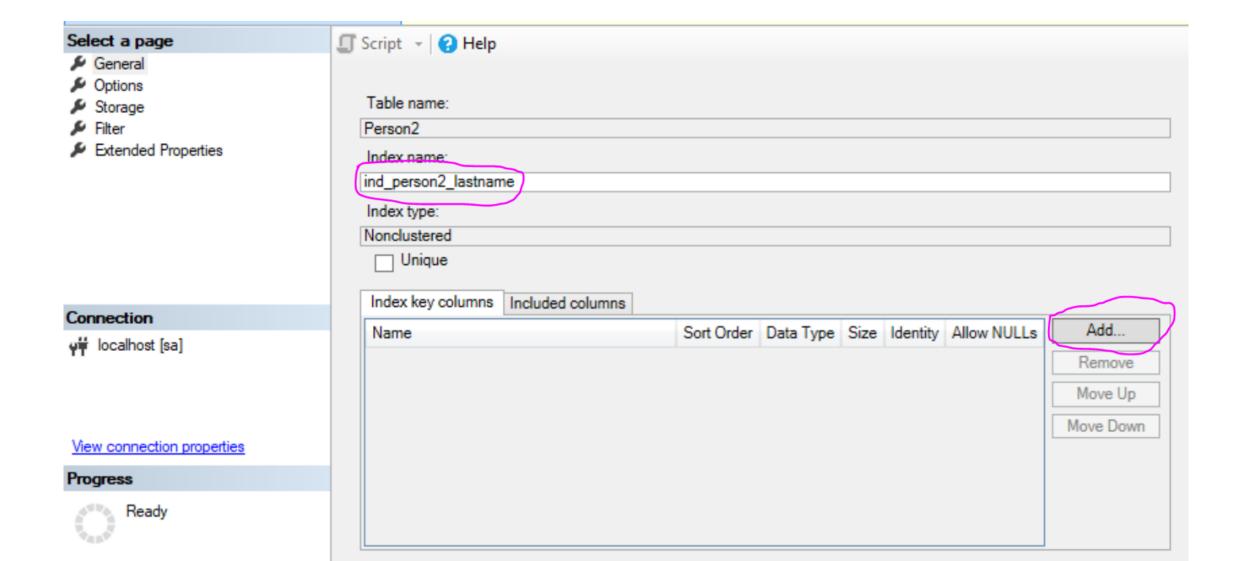
Si on a pas d'index on est obligé de parcourir toute la table ligne par ligne. Ce qui est très couteux surtout si le nombre de résultat est très important. Dans un système de production la taille de la table augmente et le temps pris par la requête augmente ce qui diminue la performance.

Si on a une index on utilise la recherche dichotomique

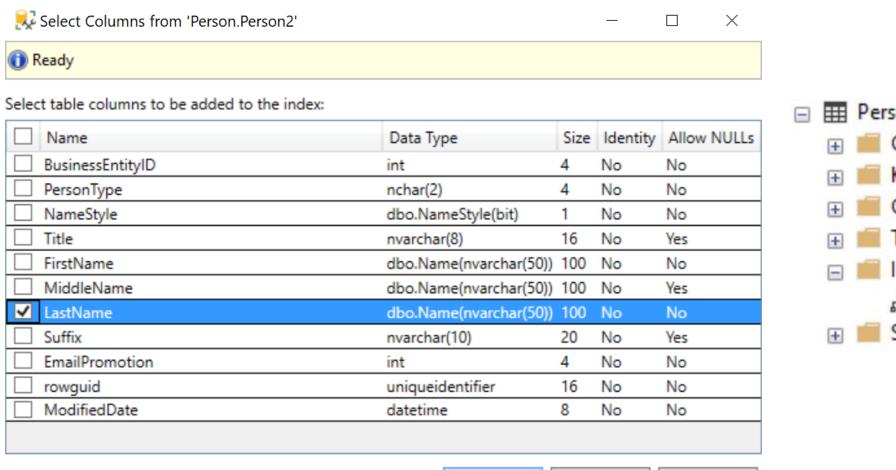
La solution: création d'un index



La solution: création d'un index



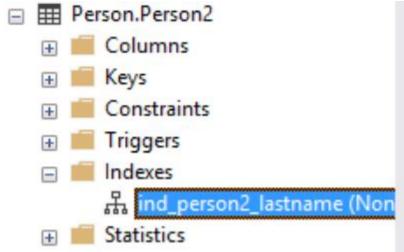
La solution: création d'un index



OK

Cancel

Help



Revoir Person 2 après ajout d'index

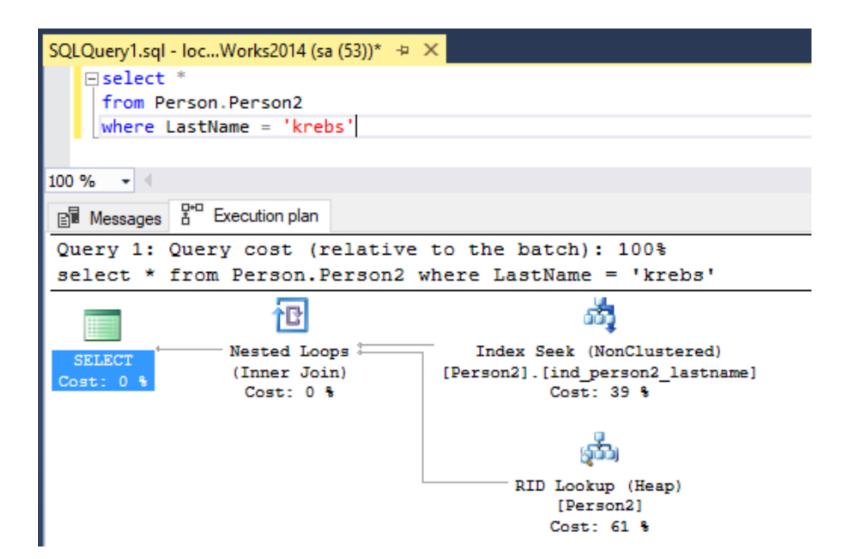
Le nombre de lecture après la création de l'index

```
SQLQuery1.sql - loc...Works2014 (sa (53))* 

select *
from Person.Person2
where LastName = 'krebs'

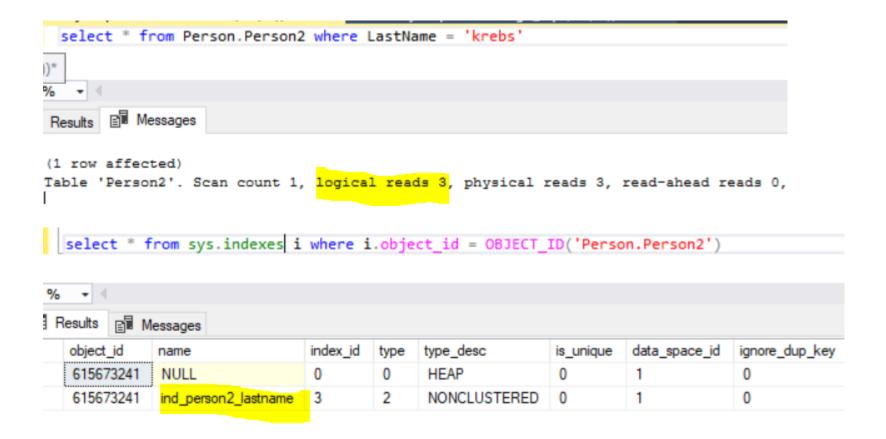
Table 'Person2'. Scan count 1, logical reads 3, physical reads 0, read-ahead reads 0,
```

Voir le plan d'exécution après la création de l'index



Aborder la recherche dichotomique sur un index

- Algorithme de recherche : la même démarche qu'on fait naturellement lorsqu'on consulte un dictionnaire.
- Si on cherche un mot « parler » précis on va pas parcourir le dictionnaire page par page : c'est un scan, c'est un parcourt de la table
- C'est pas bien et ce n'est pas efficace
- Le dictionnaire est ordonné par un ordre alphabétique
- Il faut d'abord trouver le p
- En quelques recherche on trouve le mot

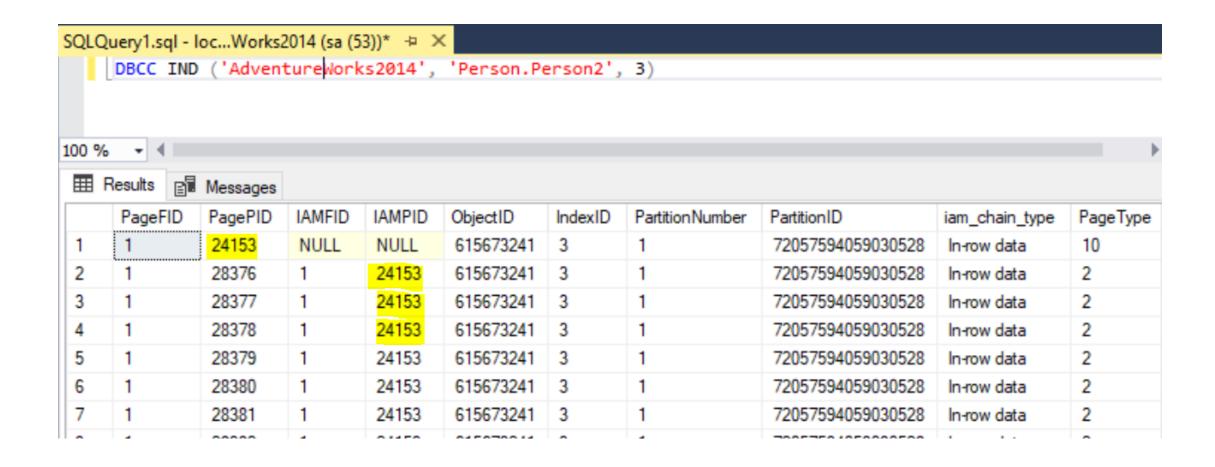


Explorer la structure d'index: structure interne de l'index

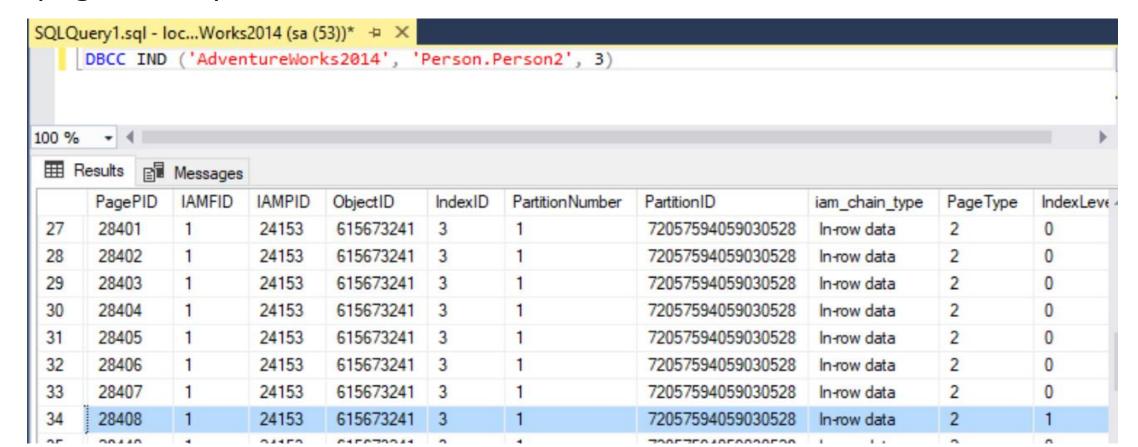
La structure : les pages qui le composent

FID: file identifiant, peut être composé de plusieurs PID

PID: page identifiant



IndexLevel: le niveau le plus élevé est la racine, le point d'entrée, la page correspondant 28408

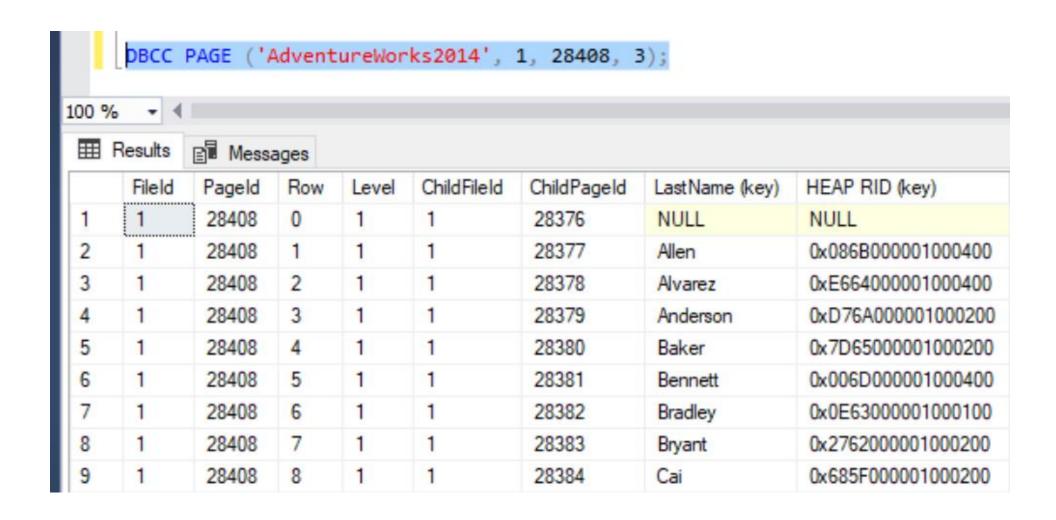


DBCC PAGE ('AdventureWorks2014', 1, 28408, 3);

La base, le FID, PID, un parameter supplémentaire pour determiner le type d'affichage, 3 pour l'affichage tabulaire.

Cette commande donne le contenu de la page.

SQL server va chercher "krebs" dans la page 28408.

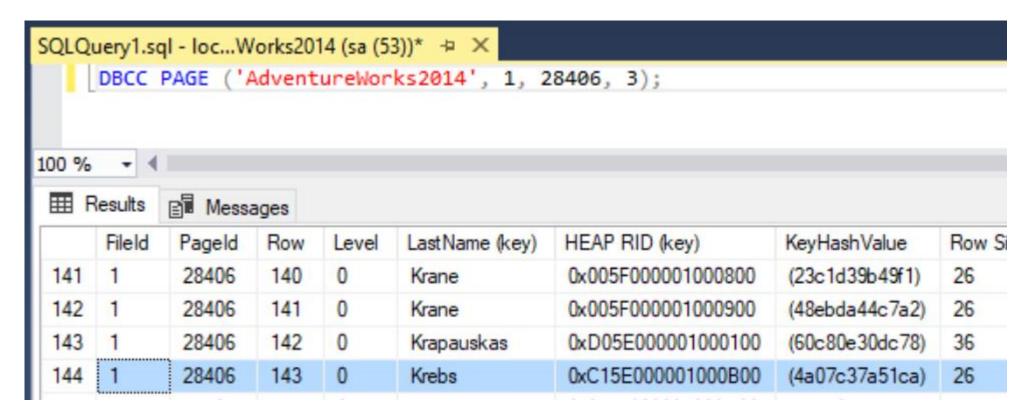


« krebs n'est pas ici mais entre « keyser » et « Lal » donc Sql server va chercher dans la page fille: 28406

Ⅲ Results		B Messa	ages					
	FileId	Pageld	Row	Level	ChildFileId	ChildPageId	LastName (key)	HEAP RID (key)
25	1	28408	24	1	1	28400	Hensien	0x365F000001000600
26	1	28408	25	1	1	28401	Hill	0x696A000001000300
27	1	28408	26	1	1	28402	Huang	0x9F6A000001000200
28	1	28408	27	1	1	28403	Jai	0x3E64000001000100
29	1	28408	28	1	1	28404	Jenkins	0xBA67000001000200
30	1	28408	29	1	1	28405	Jones	0x306B000001000300
31	1	28408	30	1	1	28406	Keyser	0xC65E000001000B00
32	1	28408	31	1	1	28407	Lal	0x2660000001000200

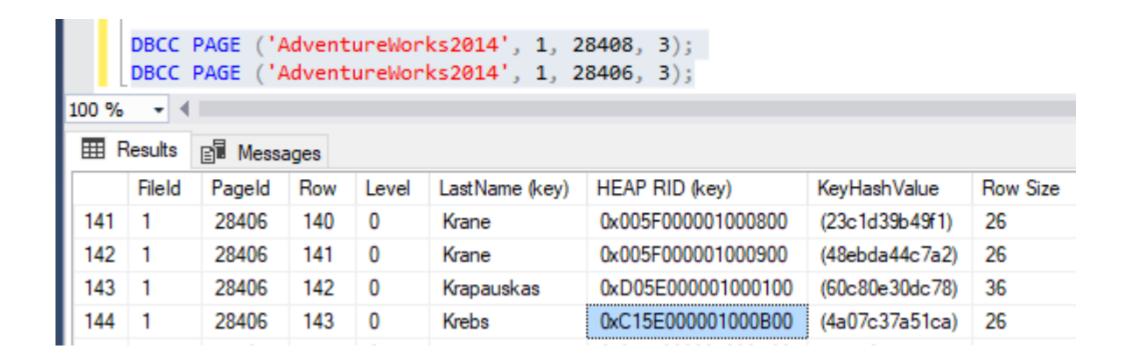
Explorer la structure d'index

HEAP RID (row ID): identifiant de ligne, rérérence pour aller chercher la ligne dans la table.



Explorer la structure d'index

Au total : 3 lectures pour trouver le résultat:



Le choix de l'optimiseur

```
SELECT (Inner Join)
Cost: 0 %

RID Lookup (Heap)
[Person2]
[Person2]
Cost: 61 %
```

A chaque fois qu'on trouve le RID on fait une recherche mais cette requête retourne un résultat d'où le choix de nested loops

Le choix de l'optimiseur

Il y a pas de garanti que l'index sera utilisé

```
SQLQuery3.sql - loc...Works2014 (sa (56))* → × SQLQuery2.sql - loc...Works2014 (sa (54))*
   select * from Person.Person3 where LastName = 'Hernandez';
100 %
               Execution plan
Query 1: Query cost (relative to the batch): 100%
           from Person.Person3 where LastName = 'Hernandez'
                  Cost: 100 %
```

Découvrir le choix par l'optimiseur

Selon le nombre de lignes qui seront affectées par cette requête l'optimiseur peut choisir n'est pas utilisé l'index

Si l'optimiseur estime que parcourir la table est moins couteux il va utiliser cette stratégie sinon il utilise l'index

Donc l'index est utilisé si l'optimiseur estime (en fonction de nombre de ligne) que l'index est sélective.

Découvrir le choix par l'optimiseur

Exécuter les requêtes suivantes et voir le plan d'exécution:

- select * from Person.Person3;
- select p.LastName from Person.Person3 p;
- select p.FirstName from Person.Person3 p;

Index couvrant

```
Il répond à tous les besoins de la requêtes:

Dans cette requête l'index n'est pas couvrant :

select * from Person.Person3 p where LastName = 'hernandez';
```

Mais dans cette requête il est couvrant : select p.LastName = 'hernandez';

La notion d'index couvrant est trés important pour la performance:

- La recherche se fait sur l'index et non sur la table
- Pas de verouillage de la table

```
//On va créer une table sans aucune contrainte ni index ni clé
create table Person.test(
id int not null identity(1,1),
texte char(20) not null default ('commentaire')
);
go
insert into Person.test default values;
go 10 -- execute la requête 10 fois
select * from Person.test
go
```

```
delete from Person.test where id = 5;
go
```

insert into Person.test default values; go

//Cette nouvelle valeur va s'insérer où ?

//Le moteur de stockag va le mettre dans l'emplacement libre si elle est suffisant

select * from Person.test go

Il n'y a pas d'ordre de ligne, on peut avoir un ordre d'affichage en utilisant order by

Cette table n'a pas d'index clustered

SQL Server considère toute table comme une forme d'index, c'est un index de type particulier, c'est un index de type HEAP

HEAP = tas, ensemble (en français), un ensemble de ligne sans ordre.

Une table est un HEAP = un ensemble non ordonné de lignes



Regarder le plan d'exécution de cette requête :

select * from Person.test where id=11

```
Query 1: Query cost (relative to the batch): 100%
select * from Person.test where id=11

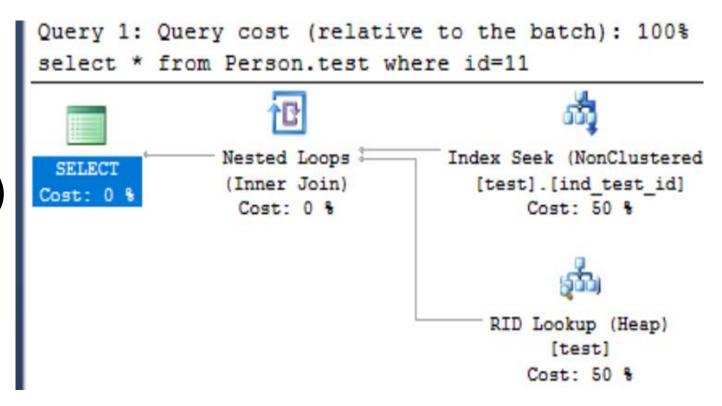
SELECT
Cost: 0 %

Cost: 100 %
```

Exécuter cette commande:

create unique index
ind_test_id on Person.test (id)

Réexécuter la commande : select * from Person.test where id=11



Voir le plan d'exécution de cette requête :

select * from Person.test

A	0	ESCIIIIACEU EXECUCION IVIOUE	NOW
_	Query cost (re	Storage	RowStore
select *	from Person.te	Estimated I/O Cost	0,003125
		Estimated Operator Cost	0,003293 (100%)
		Estimated CPU Cost	0,000168
SELECT	Table Scan [test]	Estimated Subtree Cost	0,003293
Cost: 0 %	Cost: 100 %	Estimated Number of Executions	1
		Estimated Number of Rows	10
		Estimated Row Size	31 B
		Ordered	False
l		Node ID	0

go

```
Exécuter cette requête :

drop index ind_test_id on Person.test;

go

Et puis

create unique clustered index cl_ind_test_id on Person.test (id)
```

Lorsqu'on crée un index clustered le mot clé « clustered » est obligatoire

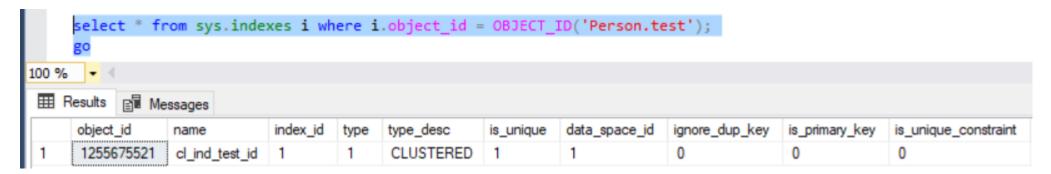
Exécuter cette requête : select * from Person.test Go

Qu'est vous remarquez ?

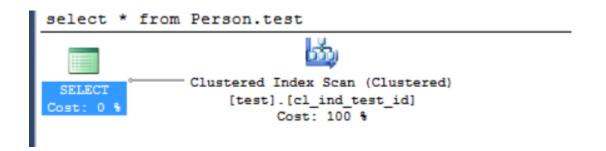


Clustered index

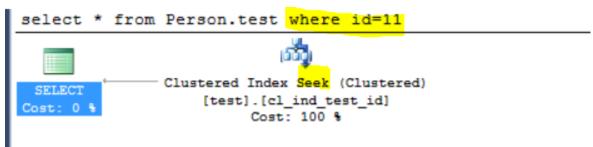
On ne voit pas la table (HEAP) car la table et l'index clustered sont la même chose



Plan d'exécution d'un index clustered



On fait une recherche pas un scan



On fait pas de boucle car l'index n'est pas couvrant

Différence entre indexes clustered et non clustered

Il est essentiel de comprendre la différence pour bien utiliser l'indexation afin d'optimiser les requêtes

L'index clustered est comme le dictionnaire: la place ou se trouve la clé, se trouve la définition

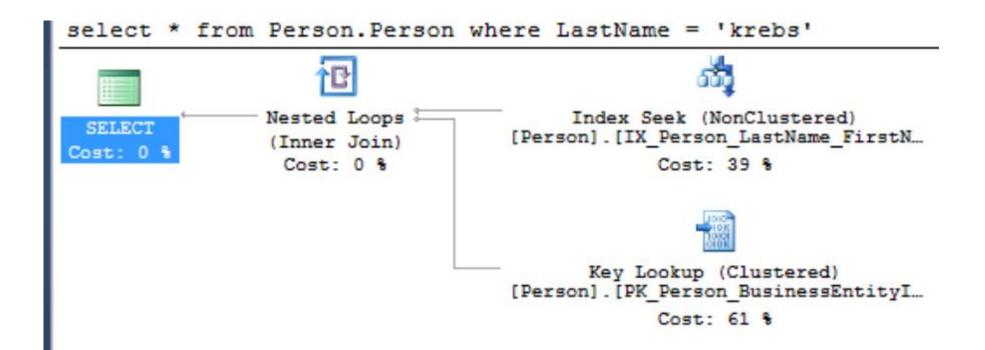
L'index non clustered c'est comme l'index en fin du livre ou on trouve le numéro de la page ensuite on cherche le contenu

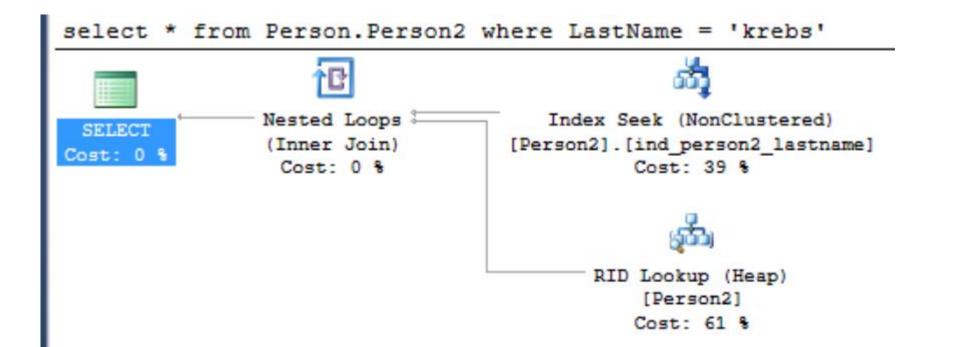
Primary Key et un index clustered

En SQL Server le PK est par défaut un index clustered, on peut changer ce comportement.

PK est une contrainte du modèle relationnel, une contrainte logique d'unicité.

Un index clustered est une structure physique





RID vs Key Lookup

